Universidad Católica de Oriente
Vigilado Mineducación

Curso: Estadistica 3
Profesor: Jose Daniel Ramirez Soto

Tarea #: 4
Tema: Clasificación de datos utilizando texto
Fecha entrega: 11:59 pm Noviembre 06 de 2023
Estudiante: Santiago Cárdenas Franco
Objetivo: Utilizar modelos de regresión logística y lstm para crear un modelo de clasificación utilizando datos reales .
Entrega: Crear una rama utilizando el mismo repositorio de la tarea 1, 2 y 3, crear otra carpeta llamada tarea 4, solucionar el problema y crear un pull request sobre la master donde me debe poner como reviewer (entregas diferentes tienen una reducción de 0.5 puntos).

1. Gradiente descendiente (15%), estaba en un parque de la ciudad y escuche un ruido constante. Entonces tomé mi celular y realice la grabación del sonido, observando la siguiente gráfica.

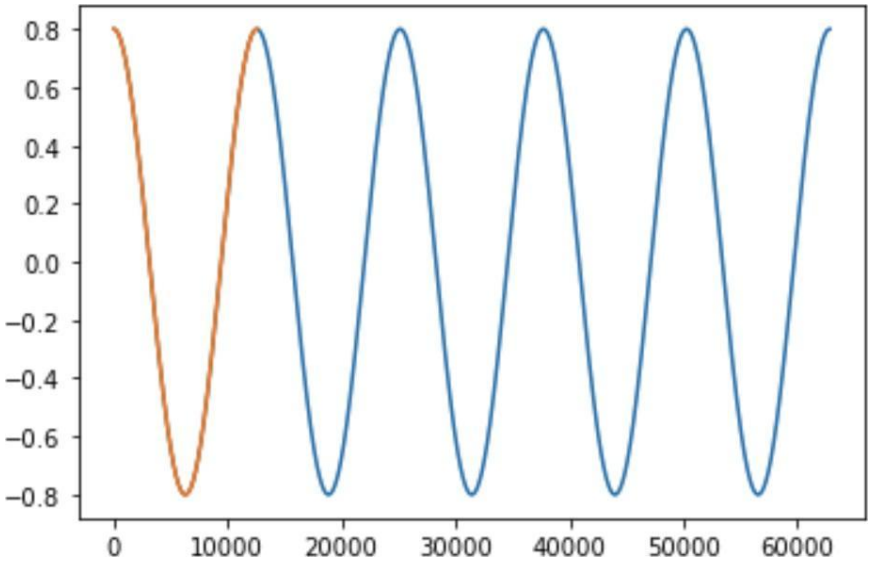

Cualquier sonido cosenoidal tiene la forma y_hat =a * cos(bx + c) + d, nuestro error debería ser LSE (Least Square Error) entonces nuestra función de error se puede escribir como e(x) = (y - y_hat)^2. Ahora con la función de error tenemos que derivar a,b,c y d=0 (Calcula el gradiente que son las derivadas parciales con respecto a a,b,c) y aplicar el algoritmo de gradiente descendiente (Considerando que el gradiente funciona solo con funciones convexas vamos a tomar la parte de la señal convexa, para encontrar los parámetros).

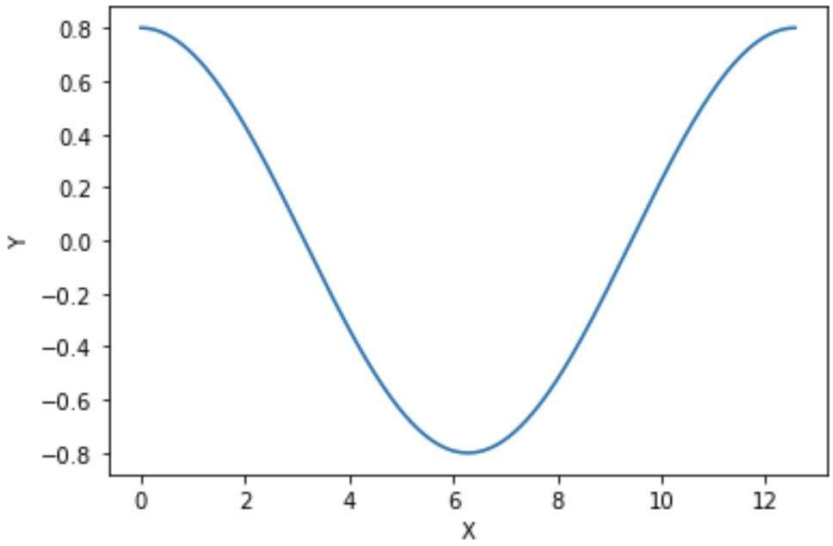

En kaggle Descarga el archivo training.csv de la competencia https://www.kaggle.com/t/944dee26bf6e4ca0b5abb29b92b5f05f el archivo training.csv aplicar el algoritmo de gradiente descendente que consiste en:

- Calcular los gradientes que son las derivadas parciales e iniciar los valores en random
- Iterar por muchos epochs (Muchas iteraciones a los datos)
- Por cada epoch toma un número de muestras aleatorias, calcula el gradiente y ajusta los valores anteriores utilizando el learning rate.
- Termina cuando el número de epochs es alcanzado

Validar el error y utilizar el siguiente código como

referencia

```
def y_predict(a,b,c,d,x):
    return a * math.cos(b*x + c) + d

lr = 0.05
n = len(x)
batch = 100
epochs = 3000
rsl = []
a = random.random()
b = random.random()
c = random.random()
d = 0
for i in range(epochs):
    a_gradiente = 0
    b_gradiente = 0
    c_gradiente = 0
    d_gradiente = 0
    e = 0
    for m in range(batch):
        ix = int(random.uniform(0,n))
        e +=  (y[ix] - y_predict(a,b,c,d,x[ix]))* (y[ix] - y_predict(a,b,c,d,x[ix]))
        a_gradiente += # * de/da
        b_gradiente += # * de/db
        c_gradiente += # * de/dc

    a = a - lr * a_gradiente/batch
    b = b - lr * b_gradiente/batch
    c = c - lr * c_gradiente/batch

    e = e/batch
    rsl.append([a,b,c,d,e])
    print(f"error:{e} period:{b} amplitude:{a} constant: {c} ")
```

E = (y- a cos (bx +c) + d) ^ 2
Utiliza los parámetros del vector rsl y crea la siguiente tabla con los datos del dataset y la función predict aprendida hasta ese epoch..

Epoch=10 (Ejemplo blue es lo aprendido)	Epoch=400

Curso: Estadistica 3
Profesor: Jose Daniel Ramirez Soto

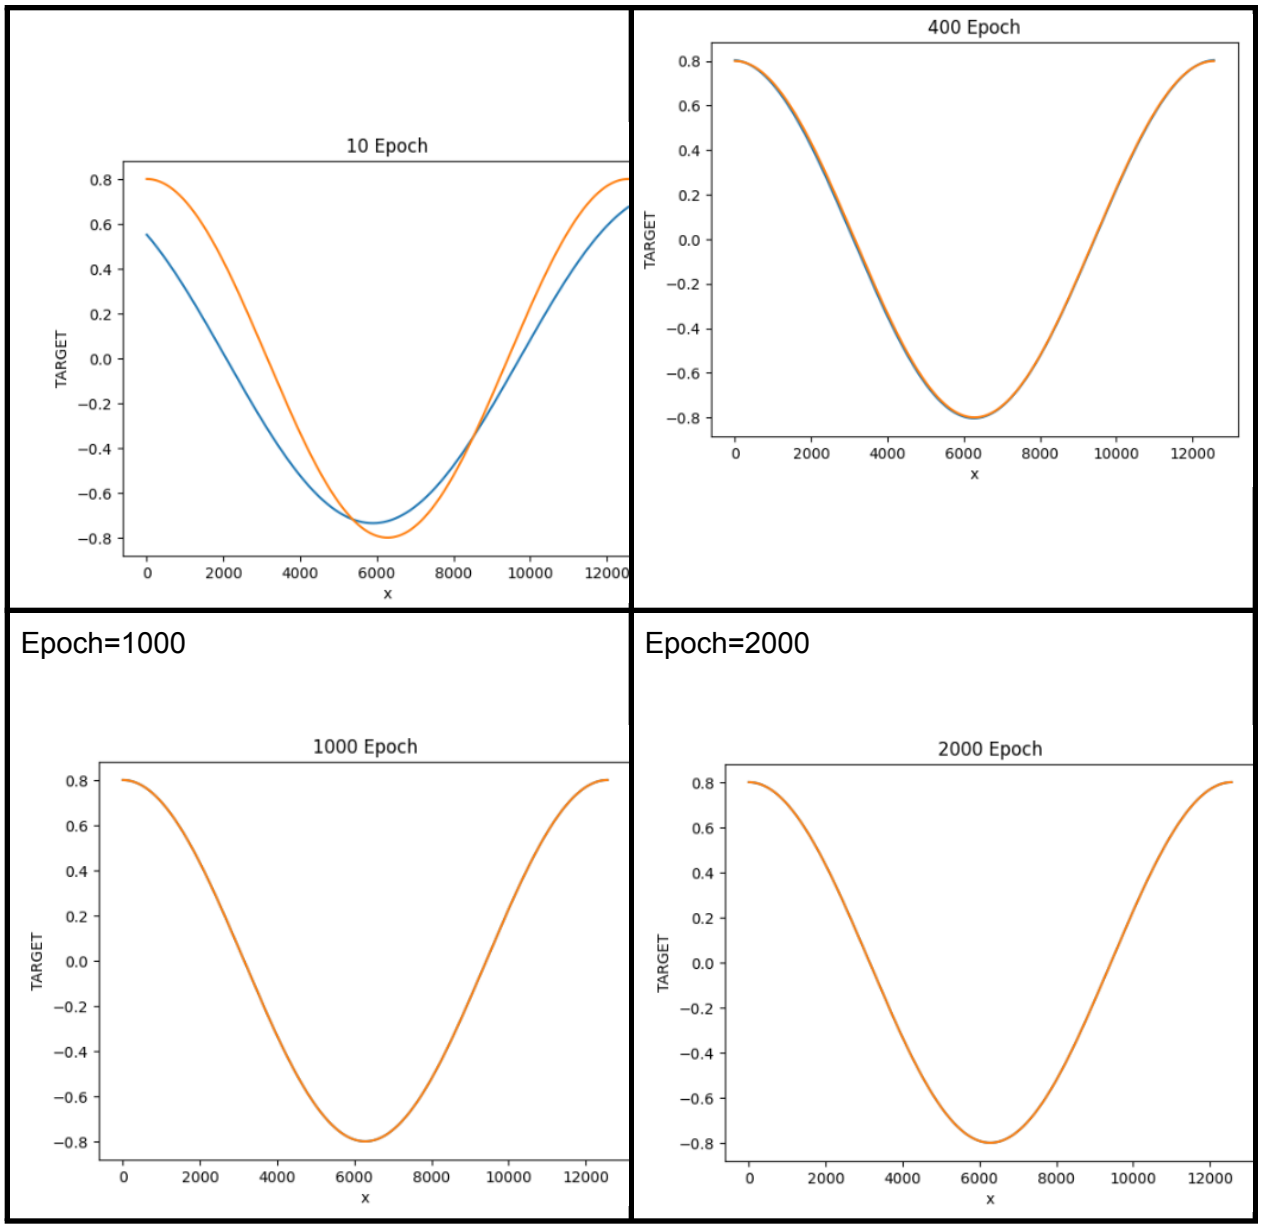

Por último utiliza los parámetros aprendidos, y crea la señal por un periodo más largo de tiempo long_s = [y_predict(a,b,c,d,xi) for xi in np.arange(x_min , 20*math.pi, 0.001).astype(np.float32)] , dibuja la señal, y escuchala utilizando la libraria (import sounddevice as sd y el método sd.play(long_s))
Ajunta el audio generado en el github y en kaggle envía la respuesta de la predicción del archivo test.

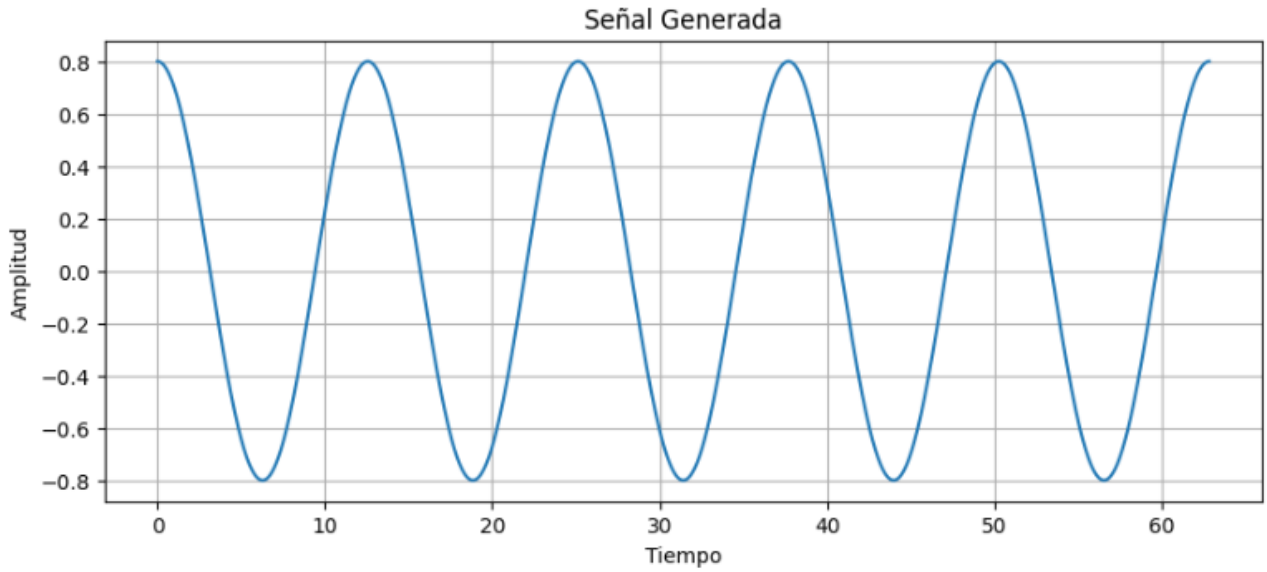

Se realizó con los datos de las 1000 épocas, si se compara los resultados de las 1000 y 2000 épocas son prácticamente iguales.

Resultado de los datos test, la línea azul es train, y la naranja es test.

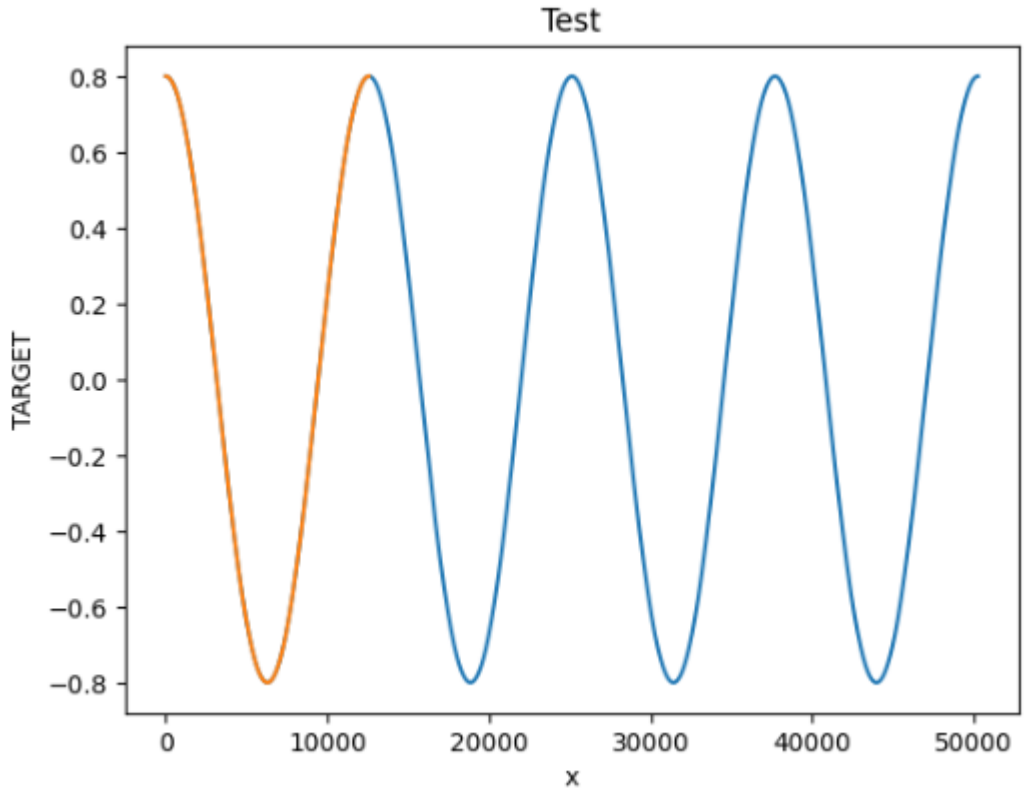

2. En kaggle https://www.kaggle.com/t/7cc94c955f244dbc9f3d1d147f592f2c Descarga el archivo training.csv de la competencia , vamos a hacer un clasificador del tipo de contenido basados en el titulo:
    a. Leer los datos en un dataframe (Puede utilizar la librería request), la variable objetivo es predecir la columna categoría (Se debe transformar

en Entretenimiento, Deportes, Película y Animación, Educación y Otros) utilizando el texto del título. Para eso es necesario hacer las siguientes tareas :

i. Utilizar todos los datos, y explorar el número total de palabras únicas en todos los títulos de train y el número total de repeticiones (Crear un diccionario para saber si la palabra ya fue observada antes e intentar remover tildes y poner el texto en minúsculas), ¿Cuántas palabras hay en el data set?, generar la siguiente matriz.

	Palabra 1	Palabra 2	Palabra 3	…	Palabra n
Titulo 1	0 (#veces palabra 1 en titulo1)				

Titulo 2		2 (#veces palabra 2 en titulo2)			
Titulo m					

ii. Normalmente las palabras más comunes son llamadas stop words. Y corresponden a los artículos o preposiciones remover las stop words. Y crear una matriz de correlación utilizando dummy variables para las variables objetivo "categoria". También generar la matrix nueva eliminando los stopwords y dividimos por el número total de palabras en cada título. Esta matriz se llama TF (Term Frequency)[1]

	Palabra 1	Palabra 2	Palabra 3	…	Palabra n
Titulo 1	0 (#veces palabra 1 en titulo1)/ Total de palabras en el Titulo 1				
Titulo 2		2 (#veces palabra 2 en titulo2)/# Total de palabras en el Titulo 2			
Titulo m					

iii. Ahora vamos a crear un vector contando el número de títulos que tiene cada palabra. Este vector tiene "n" elementos y el valor es el número de títulos que tiene la palabra. Por último vamos a transformar el número calculando el log(Total de documentos/ (Número de documentos con la Palabra i + 1)). El +1 es para q no quede el numero indeterminado cuando algún valor es "0", el vector es llamado IDF(Inverse Document Frequency) [2]

	Palabra 1	Palabra 2	Palabra 3	…	Palabra n
	log((m+1)				

[1] https://www.learndatasci.com/glossary/tf-idf-term-frequency-inverse-document-frequency/
[2] https://www.learndatasci.com/glossary/tf-idf-term-frequency-inverse-document-frequency/

	/ (# titulos con la Palabra 1 + 1))				

iv. Ahora vamos a multiplicar el vector TF (La matriz) * IDF (Vector transpuesto), El resultado es una matriz de m títulos por n palabras. Y dividir el dataset en test y train. ***En producción se debería dividir los datos antes de calcular el TF-IDF , y para calcular la matriz TFIDF en testing es necesario calcular la frecuencia de las palabras en testing utilizando el orden y las palabras en training y utilizar el IDF de training, pero no es necesario para esta tarea***.

v. Utilizando la matriz vamos a entrenar 3 modelos, una regresión logística, un random forest y una LSTM (utilizando la capa de embedding como la vimos en clase por lo tanto no es necesario el tf idf). Vamos a crear una matriz de confusión y vamos a comparar los 3 modelos. ¿Cuál es el mejor modelo?, incluir métricas como accuracy, precision y recall para cada modelo.

```
Modelo Regresión Logística:
Accuracy: 0.7169811320754716
Precision: 0.7217623777312734
Recall: 0.7169811320754716
```

```
Modelo Random Forest Classifier:
Accuracy: 0.6163522012578616
Precision: 0.6630581087558715
Recall: 0.6163522012578616
```

```
Modelo LSTM Classifier:
Accuracy: 0.6477987421383647
Precision: 0.6633666934750837
Recall: 0.6477987421383647
```

Solo observando los datos se aprecia que la regresión logística es mucho mejor a comparación de Random Forest y LSTM, la regresión logística presenta una mejor capacidad a la hora de predecir las categorías bien y al mismo tiempo de minimizar falsos positivos en comparación con los otros modelo ya mencionados, en la regresión logística hay un accuracy alto, esto que indica generalmente una correcta predicción de datos.

vi. Envia el resultado de cada modelo a kagle y documenta el accuracy de cada uno. Regresión logística, random forest y lstm.